



МІНІСТЕРСТВО ОСВІТИ І НАУКИ, МОЛОДІ ТА СПОРТУ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ»

ФІЗИКО-ТЕХНІЧНИЙ ІНСТИТУТ

Комп'ютерний практикум №1

з дисципліни КRYPTOГРАФІЯ:

«Експериментальна оцінка ентропії на символ джерела відкритого
тексту»

Виконали:

Студенти групи ФБ-96

Сендецький Костянтин

Твердохлібов Денис

Київ 2021

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Завдання

1. Написати програми для підрахунку частот букв і частот біграм в тексті, а також підрахунку H_1 та H_2 за безпосереднім означенням. Підрахувати частоти букв та біграм, а також значення H_1 та H_2 на довільно обраному тексті російською мовою достатньої довжини (щонайменше 1Мб), де імовірності замінити відповідними частотами. Також одержати значення H_1 та H_2 на тому ж тексті, в якому вилучено всі пробіли.
2. За допомогою програми CoolPinkProgram оцінити значення $(10) H$, $(20) H$, $(30) H$.
3. Використовуючи отримані значення ентропії, оцінити надлишковість російської мови в різних моделях джерела.

Хід роботи

Завдання 1

В цій частині було визначено частоти простих(з кроком 2) і перехресних біграм(з кроком 1). За цими показниками була визначена ентропія для біграм і літер. Частота біграм отсортована по їх буквенним значенням а для літер за зростанням частоти

Частоти літер

З пробілами	Без пробілів
З пробілами	Без пробілів
=====	=====
щ 0.167266	в 0.115058
т 0.0958129	и 0.0876236
е 0.0729672	а 0.0829699
а 0.0690919	т 0.0695253
х 0.0578961	э 0.0665032
д 0.0553795	ч 0.0599707
г 0.0499397	г 0.0532272
ь 0.0443241	ы 0.0502376
м 0.0418346	к 0.0471566
0.039269	ь 0.0398797
л 0.0332092	м 0.0343305
с 0.0285882	е 0.0294941
р 0.0245607	х 0.0287127
ы 0.02391	я 0.0270117
ч 0.0224936	л 0.0241532
в 0.0201132	щ 0.0215731
б 0.0179647	ц 0.0200309
э 0.0166804	э 0.0185708
у 0.0154645	р 0.0182017
к 0.0151572	н 0.017511
н 0.014582	п 0.0169074
ф 0.0140794	д 0.0163796
о 0.0136399	о 0.011349
и 0.00945074	с 0.0105287
з 0.0087676	ж 0.00855004
п 0.00711991	й 0.00778281
ш 0.00648101	б 0.00624269
ю 0.0051985	ю 0.00355561
ц 0.00296088	у 0.00287198
ж 0.00239159	ф 0.00282876
й 0.00235561	ш 0.00126171
я 0.00105067	

біграми без пробілів(20 найчастіших)

Перехресні			Прості		
	Перехресні біграми без пробілів			Прості біграми без пробілів	
то	0.0174345		то	0.0174387	
на	0.0134063		на	0.0134772	
ст	0.0128056		ст	0.0127999	
он	0.0126965		он	0.0126511	
но	0.011925		ал	0.0119654	
ал	0.0119179		не	0.011835	
не	0.0118499		но	0.0117458	
ов	0.0113221		ов	0.0113547	
ен	0.0104954		ен	0.0104238	
го	0.0100108		го	0.0101022	
ко	0.00975863		по	0.00982309	
по	0.00970975		ко	0.00978342	
ни	0.00958011		ни	0.00956239	
ос	0.00953406		ос	0.00947029	
от	0.0093272		ка	0.00932719	
ка	0.00926485		от	0.00926343	
ла	0.00918905		ла	0.00913025	
во	0.00879587		во	0.00873636	
ро	0.00827518		ро	0.00837931	
ра	0.008193		ра	0.00814695	

Біграми з пробілами(20 найчастіших)

Перехресні			Прості		
Перехресні біграми з пробілами			Прості біграми з пробілами		
о	0.0239		о	0.0239596	
е	0.0188396		е	0.018787	
а	0.0186661		а	0.0186207	
и	0.0180774		и	0.0179352	
н	0.0163707		н	0.0162409	
с	0.016117		с	0.0162409	
в	0.0147737		в	0.0147802	
то	0.0142505		то	0.0143295	
п	0.0140404		п	0.0140782	
о	0.0134594		о	0.0134328	
я	0.0111085		я	0.0111887	
и	0.0110495		и	0.0110813	
на	0.0108666		на	0.0109386	
ст	0.0104188		ь	0.0104359	
ь	0.0104064		ст	0.0103663	
не	0.0097817		не	0.00980235	
но	0.00962832		но	0.00957463	
ал	0.00951387		ал	0.0095416	
к	0.00903543		к	0.00897644	
т	0.00829566		го	0.00829094	

Ентропія для букв без пробілів: 4.4392968078807

Надлишковість: 0.10393199426244926

Ентропія для букв з пробілами: 4.348166097136004

Redundancy: 0.13036678057279916

Ентропія для перехресних біграм без пробілів: 4.122027697282843

Надлишковість: 0.16797247443734187

Ентропія для простих біграм без пробілів: 4.12094557882284

Надлишковість: 0.168190899060067

Ентропія для перехресних біграм з пробілами: 3.9422918405387293

Надлишковість: 0.21154163189225417

Ентропія для біграм з пробілами: 3.9419919173607862

Надлишковість: 0.2116016165278427

Завдання 2

Значення Н(10), Н(20), Н(30) у CoolPinkProgram

[illegible]

Лабораторная работа №1

Произвольная часть текста:
книг_под_названием_

Использованные буквы:

Порядок n-граммы:

- 5 символов
- 10 символов
- 15 символов
- 20 символов
- 25 символов
- 30 символов
- 35 символов
- 40 символов
- 45 символов
- 50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Поле ввода символов:

Продолжить Другой

Неравенство для энтропии:
 $2,41395876023665 < H < 2,99830087186149$

Двоичная таблица угаданных символов:

00000000000100000000000000000000	▲
10000000000000000000000000000000	■
01000000000000000000000000000000	
10000000000000000000000000000000	
01000000000000000000000000000000	▼

Вероятности:

q[1]	= 0,42
q[2]	= 0,18
q[3]	= 0
q[4]	= 0,02
q[5]	= 0,02
q[6]	= 0
q[7]	= 0,02
q[8]	= 0
q[9]	= 0,02
q[10]	= 0
q[11]	= 0
q[12]	= 0,06
q[13]	= 0,02
q[14]	= 0,04
q[15]	= 0,02
q[16]	= 0
q[17]	= 0,06
q[18]	= 0,02
q[19]	= 0,02
q[20]	= 0,02
q[21]	= 0,02
q[22]	= 0
q[23]	= 0
q[24]	= 0
q[25]	= 0,02
q[26]	= 0
q[27]	= 0
q[28]	= 0,02
q[29]	= 0
q[30]	= 0
q[31]	= 0
q[32]	= 0

Строка состояния:

Произвольная часть текста:
ободы_выбора_чем_ч_камня_упас

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Поле ввода символов:

Продолжить Другой

Неравенство для энтропии:
 $2,38429608304325 < H < 2,95400999571957$

Двоичная таблица угаданных символов:

00000100000000000000000000000000
01000000000000000000000000000000
00000000010000000000000000000000
10000000000000000000000000000000
00000000100000000000000000000000

Вероятности:

$q[1] = 0,4$
$q[2] = 0,22$
$q[3] = 0$
$q[4] = 0,02$
$q[5] = 0$
$q[6] = 0,04$
$q[7] = 0,02$
$q[8] = 0,04$
$q[9] = 0,02$
$q[10] = 0,02$
$q[11] = 0$
$q[12] = 0$
$q[13] = 0,04$
$q[14] = 0$
$q[15] = 0$
$q[16] = 0$
$q[17] = 0,02$
$q[18] = 0,02$
$q[19] = 0$
$q[20] = 0$
$q[21] = 0,02$
$q[22] = 0$
$q[23] = 0$
$q[24] = 0,04$
$q[25] = 0$
$q[26] = 0,02$
$q[27] = 0$
$q[28] = 0$
$q[29] = 0,04$
$q[30] = 0$
$q[31] = 0$
$q[32] = 0,02$

Строка состояния:

Отримали значення

$$2.3289 < H(10) < 2.8500$$

$$2.4139 < H(20) < 2.9993$$

$$2.3842 < H(30) < 2.9540$$

Знаходимо значення надлишковості джерела відкритого тексту

$$0,5342 > R(10) > 0,4300$$

$$0,5172 > R(20) > 0,4001$$

$$0,5231 > R(30) > 0,4092$$

Висновки: Засвоїли поняття ентропії на символ джерела та його надлишковості, вивчили та порівняли різні моделі джерела відкритого тексту для наближеного визначення ентропії, набули практичних навичок щодо оцінки ентропії на символ джерела.